Test ve Öğrenimler

Private Banking RM Yatırım Karar Destek Çözümü · Teslimat 5 · veri tarihi 9 Ekim 2026, ölçümler 15 Ekim 2026

150	0	1,6 sn	7
otomatik test, 14 dosya, hepsi geçiyor	finalistte kısıt ihlali (5 persona, 40 öneri)	5 persona, 1.050 ürün, kural + skor	belgelenmiş hata analizi ve iyileştirme

1. “Çözümümüz iyi çalışıyor” nasıl gösterildi?

Tek bir doğru ürün sıralaması olmadığı için (brief bölüm 9) doğruluğu bir etikete karşı değil, **bir RM’in güvenmesi için gerekli özelliklere** karşı ölçtük. Her gösterge, değerlendirme boyutlarından birine bağlıdır.

Gösterge	Neden seçildi	Nasıl ölçüldü	Sonuç
Müşteri kısıtına uyum	Uyumsuz ürün öneri listesine girmemeli (brief madde 5).	Her persona için finalistlerde risk üst sınırı ve nitelikli yatırımcı şartı denetlendi; ayrıca kural motorunda “ihlal = 0” değişmezi testle korunuyor.	**40 finalistte 0 ihlal**
Tekrarlanabilirlik	Aynı girdi, aynı kayıt olmalı; RM’e güven.	Tüm personalar için kanıt kaydı iki kez üretilip birebir karşılaştırıldı (kural sonuçları, skorlar, sıralama, veri noktaları).	**birebir aynı**
Kaynak doğruluğu	Her sayının kaynağı ve tarihi olmalı, uydurma olmamalı.	Her finalistin her veri noktasında kaynak alanı zorunlu; değer yoksa “yok” (testli). LLM metninde sayı yazılamaz, sayıları kod kanıt kaydından basar.	**tüm veri noktaları kaynaklı**
Eksik/çelişkili veri davranışı	Jüri veri erişimini veya müşteri bilgisini değiştirebilir.	9 kontrollü senaryo (bölüm 3): veri kaynağı yok, müşteri bilgisi değişti, çelişkili bilgi, yeni kısıt.	**çökme veya uydurma yok (iki hata bulundu ve düzeltildi, bölüm 5)**
Seçimin kararlılığı	Ağırlıklar biraz oynayınca liste kökten değişmemeli.	Ağırlıklı her sinyal ±%20 oynatıldı (persona başına 14-16 senaryo); finalist kümesinin tabanla örtüşmesi (Jaccard).	**ort. 0,88–0,98**
Açıklanabilirlik	RM “neden bu fon?” ve “neden yok?” sorusuna cevap bulmalı.	Finalist başına kural sonuçları (kaynak etiketli), skor dökümü, uzlaşma bayrağı; her elenen ürün için elenme nedeni; 1.050 ürünün tamamı hunide sayılıyor.	**kanıt kaydı + arayüz**
İşlem süresi	Görüşme öncesi hazırlığa katkı.	Süre ölçümü (bölüm 4).	**saniyeler; LLM metni dakikalar**
RM hazırlık katkısı (zaman tasarrufu)	Brief’in sayabileceği boyutlardan biri.	**Ölçmedik. Gerçek RM ile süre karşılaştırması yapılmadı; yalnızca 1.050 ürünün 8 finalist + gerekçeye indiği gösterilebilir.**	

2. Test envanteri (150 test)

Alan	Test	Neyi sınıyor
Veri katmanı	44	TEFAS/KAP/SPK/TCMB okuyucuları, sınıflandırma, risk değeri ayrıştırma, valör, ücret, vergi tablosu; bozuk girdide uydurma yapmama
Kural motoru	16	Risk profili, likidite, vadeli fon, nitelikli yatırımcı, döviz, yoğunlaşma; “ihlal = 0” değişmezi; deterministik
Skorlama ve istatistik	8 + 11 + 9	Sinyaller, ağırlıklar, finalist kapıları; Wilson, Bayes büzülmesi, dört karar yöntemi; vergi, komisyon, tarihsel grafikler
Kanıt kaydı ve anlatım	8 + 11	Her finalistin kayıt bütünlüğü, huni toplamları; LLM çıktısı korumaları (rakam, başka ürüne atıf, yasaklı ifade, yeniden deneme, hata hâlinde metin üretmeme)
Jüri Challenge, LLM katmanları	19 + 8	Kısıt doğrulayıcı, senaryo uygulayıcı, veri erişimi, RM seçimi, ensemble beraberlik kuralı, muhakeme ve karşılaştırma korumaları
İş akışı ve arayüz	3 + 5 + 1 + 2 + 5	Onay kaydı, onaylı teklif; Streamlit uçtan uca akışlar (5 persona, tüm görünümler, fon ekleme/kaldırma); persona yükleme

Gerçek yerel modelle (Ollama) yapılan denemeler otomatik teste dahil değildir (model ve süre bağımlı); sonuçları bölüm 4’tedir. Testlerde LLM yerine sahte model kullanılır.

3. Sonuçlar

3.1 Persona bazında

Persona	Uygun	Teyit gerekli	Elendi	Derinlik kapısı elenen	Jaccard ort / min	4/4 uzlaşan finalist
P01 Muhafazakâr	211	41	781	192	0,92 / 0,78	4 / 8
P02 Dengeli	268	181	584	255	0,94 / 0,78	2 / 8
P03 Agresif	747	158	126	706	0,88 / 0,60	3 / 8
P04 Dengeli	282	167	584	255	0,98 / 0,78	2 / 8
P05 Temkinli	151	96	786	192	0,94 / 0,78	4 / 8

Her persona için 1.050 ürün değerlendirildi (1.046 fon + 4 mevduat referansı); 17-19 ürün veri eksikliğinden değerlendirilemedi ve öneriye girmedi. P03’ün en düşük Jaccard değeri (0,60) bir ağırlık değişince 8 fonluk listeden 2 fonun değiştiği bir senaryo olduğunu gösterir (dörtte bir): bu persona için seçim diğerlerine göre daha duyarlıdır ve RM’e bu bilgi sunulur.

3.2 Jüri Challenge senaryoları (müşteri bilgisi, kısıt, veri erişimi)

Senaryo	Sistem davranışı	Süre
P03: risk profili Agresif → Dengeli	Uygun 747 → 282; finalistlerin 7'si değişti, 1'i kaldı; ihlal 0	0,8 sn
P03: risk → Temkinli	Çelişki tespit edildi (anapara koruma "Düşük" ile uyumsuz); **tahmin yapılmadı, RM teyit sorusu üretildi**	0,6 sn
P03: likidite ihtiyacı → Yüksek	Çelişki (ufuk 5+ yıl ile); RM teyit sorusu	0,5 sn
P01: KAP risk değeri erişilemiyor	Risk bilinmeden fon değerlendirilemez: 920 ürün "değerlendirilemedi", **finalist yok, uydurma yok**	0,2 sn
P01: TEFAS fiyat verisi erişilemiyor	Fiyat geçmişi yok: 265 ürün değerlendirilemedi, finalist yok	0,2 sn
P01: KAP ücret bilgisi eksik	Ücret "bilinmiyor" işaretlendi (nötr skor, notlu); 8 finalistin 7'si değişmedi	0,3 sn
P05: Ak Portföy dışla + risk ≤ 1	Uygun 60, finalist 8 (5'i yeni); ihlal 0	0,3 sn
P02: ücret ≤ %0,5 + döviz yok	Uygun 18, **yalnızca 5 finalist**: koşulu sağlayan yeterli fon yok, liste uydurmayla doldurulmadı	0,3 sn
P04: serbest fon istemiyor	Düzeltme sonrası serbest döviz fonu (DAS) da çıktı (bölüm 5, hata 6)	0,5 sn

4. LLM katmanlarının yerel modellerle ölçümü

Üç yerel model (Ollama) aynı istemlerle 5 persona üzerinde denendi. **Önemli ilke:** sayıları model yazmaz, kod kanıt kaydından basar; model yalnızca düzyazı yazar ve çıktısı doğrulanır.

Model	Geçen	İlk denemede	Ort. süre	Gözlem
gemma3:12b (seçildi)	5/5*	3	~166 sn (78-263)	Ürüne özgü, dengeli yorum. *İki başarısız vaka kendi kodumdaki hatalardan çıktı (fon adındaki "BIST 30", "Garanti Portföy" yanlış alarmı; ürünleri birbiriyle kıyaslama); düzeltilip yeniden koşuldu.
qwen2.5:7b	5/5	3	76 sn	Her ürüne aynı kalıp cümle
llama3.1:8b	4/5	4	61 sn	"ideal bir seçenektir" gibi satış dili (yönlendirme riski)

Katman	Gerçek model denemesi	Süre
Kısıt yorumlayıcı (Jüri)	5 cümlenin 4'ü doğru kısıta çevrildi ("6 ay içinde ev alacak" → likidite Yüksek + ufuk 1 yıldan kısa; "Ak Portföy istemiyor" → şirket dışlama; veri erişimi; ücret + döviz). İlgisiz cümle ("hava güzel") **kısıt üretmedi, "belirsiz" diye ayrıldı**	8–17 sn
Persona uyumu muhakemesi	P01 ve P03 ilk denemede geçti; öneriler kod doğrulamasından geçti	~65 sn
Fon karşılaştırması	P01'de dört fon için güçlü/dikkat yorumu ilk denemede geçti	~62 sn

5. Hata analizleri ve iyileştirmeler

Aşağıdaki hataların çoğu otomatik testle veya senaryo çalıştırırken bulundu; her biri için kök neden, düzeltme ve tekrarını önleyen test belirtilmiştir.

Hata 1 · 202 fonun oynaklığı boştu (veri hatası)

Belirti. P03'ün ilk sırasındaki fonun (CPU) haftalık oynaklığı "yok", ama 150 haftalık verisi vardı. Toplam 202 fonda oynaklık boştu.

Kök neden. Bazı fonlarda kuruluş gününe ait TEFAS fiyatı `0,0` geliyordu; ilk haftalık getiri sonsuz çıkıyor, standart sapma hesaplanamıyordu (sessizce `NaN`).

Düzeltme. Fiyatı sıfır veya negatif olan günler hesaptan çıkarıldı. **Sonuç:** oynaklığı boş fon 202 → 0; risk bantları ve istikrar skoru etkilenen fonlarda doğru hesaplandı, P03 finalistleri değişti.

Hata 2 · LLM doğru sayıyı yanlış yere koyuyordu (tasarım hatası)

Belirti. İlk tasarımda sayıları modelden istedik ve "her sayı kanıtta var mı" diye denetledik. qwen2.5 "1050 ürün *elendi*" yazdı (gerçek: 786 elendi, 1050 değerlendirilen) ve "ZBJ (Kod: 1)" ile sıra numarasını kod sandı. Her iki metin de sayı denetimini geçti, çünkü sayılar kanıtta vardı, yalnızca yanlış yerdeydi.

Kök neden. Sayı koruması bir sayının varlığını doğrular, anlamını değil. Küçük yerel modellerde bu sık görülür.

İyileştirme (mimari). Sayıları ve sayımları **kod** basıyor, model yalnızca düzyazı yazıyor; düzyazıda **hiç rakam olamaz**, her yorum yalnızca kendi ürün kodunu anabilir, uydurma kod reddedilir. Bu hata sınıfı yapısal olarak ortadan kalktı. Ürün yorumu geçmezse önce yalnızca o yorum yeniden yazdırılır (hızlı), olmazsa metin hiç gösterilmez.

Hata 3 · Onaylanan öneri ile uygulanan değişiklik farklıydı (iş akışı hatası)

Belirti. LLM önerisi "ZBJ yerine IDL" idi, RM onayladı, ama sistem IDL'yi en düşük skorlu fonun (YBS) yerine koydu.

Düzeltme. Ek aday kaydı hangi finalistin çıkacağını saklıyor; RM kendi seçiminde "hangi finalist çıksın" alanını seçiyor. Kayıtlar silinmez (ekleme ve kaldırma ayrı satırlar). Testlerle doğrulandı.

Hata 4 · Jüri yolunda iki çökme

(a) Müşteri bilgisi çelişkili olunca `KeyError: 'finalists'`: motor çelişkiyi doğru tespit ediyordu ama sonucu karşılaştıran iş akışı koduna finalist listesi gelmiyordu. Senaryolar belgeyi yazarken çalıştırılınca bulundu; düzeltildi, regresyon testi eklendi. **(b)** Hiç aday kalmayınca (veri erişilemiyor senaryosu) duyarlılık analizinde sıfıra bölme. **(c)** LLM'in kısıt değerini liste olarak döndürmesi (`['AK PORTFÖY']`) doğrulayıcıyı çökertiyordu; doğrulayıcı artık hiçbir girdide istisna fırlatmıyor ve liste değerleri ayrı kısıtlara açılıyor.

Hata 5 · Ensemble seçimi agresif personaya para piyasası fonu getirdi

Belirti. Fon seçimini dört karar yönteminin uzlaşmasına bağlayınca agresif P03'ün listesinde üç para piyasası fonu (ZBJ, DIP, EIL) göründü.

Kök neden. Sıra yüzdelerinin ortalaması, maliyet, likidite, tutarlılık gibi yan sinyallerde iyi olan düşük riskli fonları öne çıkarıyor ve personanın ağırlıklarını (risk uyumu, getiri) sulandırıyor.

İyileştirme. Ensemble seçimi değiştirmiyor: ana sıra ağırlıklı toplamda kaldı; ensemble her fon için "yöntemler uzlaşıyor / tartışmalı" bayrağı üretiyor ve yalnızca skorları birbirine çok yakın adaylar arasında belirleyici. Eski davranış yapılandırmada tek anahtarla denenebilir. **Kalan sorun:** P03'te hâlâ bir para piyasası fonu (EIL) var; bu, son 12 ayda para piyasasının hisseyi geçmesini yansıtıyor (rejim etkisi), model hatası değil ama agresif, 5+ yıl ufuklu müşteriye yakışmayabilir (bölüm 7).

Hata 6 · "Serbest fon istemiyor" serbest döviz fonunu elemiyordu (kapsam hatası)

Belirti. P04 için "serbest kategorisini dışla" senaryosu hiçbir şeyi değiştirmedi; listedeki DAS fonu "serbest döviz" kategorisinde.

Düzeltme. "Serbest" bir fon *türüdür*: serbest döviz ve adında para piyasası geçen serbest fonlar da kapsanıyor. Test eklendi; DAS artık çıkıyor.

Hata 7 · Arayüz hataları (görsel doğrulamanın değeri)

Streamlit'in yerleşik tablo ve grafik bileşenleri tarayıcıda "LargeUtf8" hatası veriyordu (otomatik test yakalamadı, çünkü hata tarayıcı tarafındaydı); kendi HTML tablolarımıza geçildi. Yeniden başlatma komutum eski sunucuyu kapatmadığı için değişiklikler görünmedi. Çizgi grafiğin bitiş etiketi ondalık virgül değişimi koordinatlara da bulaştığı için yanlış yerde çıktı. Bunlardan sonra her arayüz değişikliği **canlı sayfanın ekran görüntüsüyle** doğrulandı.

Ölçümle verilen iki karar

Bayes büzülmesi: kategori içi mi, tek havuz mu? Önce "sağduyuyla" tek havuz seçtim; kategori içinde büzülmenin yüksek oynaklıklı kategorilerin hepsini ortancaya çökerttiğini düşündüm. Yerel TEFAS geçmişinde geriye dönük test koştum: geçmiş 12 aylık getirinin sonraki 6 aylık getiri sırasını öngörmesi (Spearman, 6 pencere ortalaması):

Yöntem	2025-01	2025-04	2025-07	2025-10	2026-01	2026-04	Ortalama
Ham getiri	0,296	0,258	0,357	0,066	0,110	0,188	**0,212**
Tek havuz büzülmesi	0,294	0,226	0,344	0,188	0,116	0,231	**0,233**
Kategori içi büzülme	0,318	0,318	0,365	0,134	0,157	0,255	**0,258**

Kategori içi büzülme en iyi sıralamayı verdi; sağduyum veriyle çelişti ve veri kazandı. **Sınır:** fark küçük (+0,05) ve yalnızca 6 pencereye dayanıyor; "büzülme kesin iyileştirir" demiyoruz, "ham getiriden kötü değil, biraz daha iyi" diyoruz. Betik `tools/backtest_shrinkage.py` içinde, ağ isteği olmadan yeniden çalıştırılabilir.

Wilson alt güven sınırı. Aynı "%100 başarı" az veriyle daha az güvenilirdir: 36/36 ay → 0,93; 12/12 → 0,82; 3/3 → 0,53; 18/24 → 0,59. Tutarlılık sinyali (aylık getirinin aylık TÜFE'yi geçmesi) bu yüzden ham oran yerine alt sınırı kullanır; kısa geçmişli fon doğru cezalandırılır (elle doğrulanmış değerlerle testli).

6. Vergi ve komisyon eklemesinin etkisi

Stopaj (gerçek kişi, yeni alım, kaynaklı tablodan okunur) ve komisyonlar (yatırım ufkuna yayılmış) eklendi. Ölçülen etki küçük: finalist listesinde en fazla bir fon değişti (P01'de YBS → VFK), P02, P04, P05 aynı kaldı. Yani bu iki ek, seçimi bozmadan getiri ve maliyetin gerçekçiliğini artırdı; hisse yoğun fon (%0) ile para piyasası fonu (%17,5) artık karşılaştırmada doğru görünüyor.

7. Bilinen sınırlar (dürüst değerlendirme)

- **"Doğru seçim" için referans etiket yok.** Ensemble ve büzülme geçmiş getiriyi sıralamayı ölçtü; "RM'in tercih edeceği ürünü" ölçmedi. Bunun için RM kararlarının birikmesi gerekir (kararlar kayıt altında).
- **Getiri rejimi etkisi.** Son 12 ayda TL para piyasası hisse ve altını geçti; getiri sinyali küçük ağırlıklı olsa da bu, agresif personaya bir para piyasası fonu sokabiliyor. Daha uzun geçmiş ve rejim ayrımı gerekir.
- **Valör tanımı tahmindir.** TEFAS'a istek atmadığımız için kategoriye ve KAP metnine dayalı kendi ön tanımımızı kullanıyoruz; serbest fonlarda valör bilinmiyor.

- **Vergi eşlemesi yorumdur.** Fon türü → tablo satırı eşlemesinde belirsiz olanlar “RM teyit” etiketli; yeni alım içindir, eski pozisyonlar ve elde tutma süresi koşulları kapsam dışı.
- **LLM yorumu anlamsal olarak doğrulanamaz.** Kod; sayı, kod ve yasaklı ifadeyi denetler, “personada olmayan bir tercihi uydurma” gibi anlamsal hatayı yakalayamaz (muhakeme denemesinde bir örnek görüldü). Bu yüzden öneri kartlarında “LLM gerekçesi, doğrulanmadı” notu ve skor bedeli (kodla hesaplanmış) gösterilir, uygulama RM onayına bağlıdır.
- **Yerel LLM yavaş.** RM notu 1-4 dakika sürer; demoda önceden üretilip önbelleğe alınması gerekir.
- **Kapsam.** Personalar sentetiktir; RM kimlik doğrulaması yoktur (serbest metin kimlik); veri tarihi 9 Ekim 2026.

8. Öğrenimler

- **Denetimin neyi doğruladığını bil.** “Sayı kanıtta var” denetimi yanlış yerdeki doğru sayıyı geçirdi; çözüm daha çok denetim değil, hata sınıfını mimariden kaldırmaktı (sayıları kodun basması).
- **Sağduyu yerine ölçüm.** Büzülme seçiminde ve ensemble kullanımında ilk sezgilerim iki kez veriyle çelişti.
- **Senaryo çalıştırmak test yazmaktan farklı şeyi bulur.** Müşteri bilgisi çelişkisinde çökme ve “serbest” kapsamı, birim testlerden değil, gerçek senaryolar koşulurken çıktı; ikisi de artık testli.
- **Yapay zekâ yardımcıdır, karar verici değil.** LLM yalnızca düzyazı yazıyor, serbest metni şemaya çeviriyor ve öneri sunuyor; kuralları aşamaz, hiçbir şey RM onayı olmadan uygulanmaz.